



Clasificación del Riesgo de Inundación en las Parroquias de la Provincia del Guayas

Proyecto Final de Materia

Correa Preciado	– Introducción y descripción de datos
Franco Junior	– Metodología y variable objetivo
Mora Carlos	– Variables predictoras
Rivas Toala	– Análisis exploratorio de datos
Perugachi Reyes	– Modelos, resultados y discusión
Domenech Juan	– Conclusión

10 de julio de 2026

Índice

1. Introducción y contextualización del problema en Ecuador	2
1.1. Descripción de los datos y su origen	2
2. Metodología aplicada (EDA + modelos)	2
2.1. Construcción de la variable objetivo	3
2.2. Variables predictoras y variable derivada	3
2.3. Análisis Exploratorio de Datos (EDA)	4
2.4. Modelos de clasificación aplicados	6
2.5. Resultados obtenidos	7
3. Discusión y limitaciones del estudio	9
4. Conclusión	10
Referencias	10

1 Introducción y contextualización del problema en Ecuador

El Ecuador presenta una elevada vulnerabilidad frente a eventos hidrometeorológicos extremos, particularmente inundaciones, las cuales se intensifican durante las temporadas de lluvia en las regiones Costa y Amazonía. La provincia del Guayas, ubicada en la región Costa, concentra una combinación de factores de riesgo: terrenos de baja altitud, alta densidad poblacional en zonas urbanas y rurales, y un régimen de precipitaciones marcadamente estacional que históricamente ha derivado en eventos de inundación con impacto significativo sobre la población, la infraestructura y la actividad agropecuaria.

De acuerdo con la división político-administrativa del país, la parroquia constituye la unidad territorial mínima que dispone de información demográfica, geográfica y climática suficiente para realizar un análisis de riesgo con enfoque local. Bajo este criterio, el presente proyecto tiene como finalidad diseñar e implementar un modelo de clasificación supervisada que permita determinar el nivel de riesgo de inundación de las 54 parroquias que conforman la provincia del Guayas, integrando variables de naturaleza climática y socio-territorial obtenidas de fuentes oficiales abiertas.

El objetivo específico del proyecto es construir un pipeline completo de aprendizaje automático que, a partir de variables predictoras como la precipitación histórica, la densidad poblacional y la altitud, permita clasificar cada parroquia en una categoría de riesgo de inundación. Este resultado se integra posteriormente en una aplicación web con visualización geográfica interactiva, con el fin de que la información generada sea accesible para fines de gestión de riesgo a nivel parroquial.

1.1 Descripción de los datos y su origen

El conjunto de datos utilizado se construyó a partir de la integración de fuentes oficiales abiertas, unificadas mediante el código oficial de parroquia (DPA_PARROQ), e incluyó capas geográficas oficiales, registros históricos de eventos de inundación del Servicio Nacional de Gestión de Riesgos y Emergencias (SNGRE) y datos de densidad poblacional del Instituto Nacional de Estadística y Censos (INEC).

2 Metodología aplicada (EDA + modelos)

El desarrollo del proyecto inició con un Análisis Exploratorio de Datos (EDA), cuyo objetivo fue conocer la estructura del conjunto de datos, identificar valores faltantes, revisar los tipos de variables y analizar la distribución de la información. Además, se realizaron estadísticas descriptivas y visualizaciones para comprender el comportamiento de variables como la precipitación, la altitud y otros factores relacionados con el riesgo de inundación.

Posteriormente se efectuó el preprocesamiento de los datos, que incluyó la limpieza de re-

gistros, la integración de las diferentes fuentes de información y la creación de la variable objetivo denominada riesgo, clasificada en los niveles Bajo, Medio y Alto.

Una vez preparado el conjunto de datos, se dividió en conjuntos de entrenamiento y prueba para entrenar los modelos de aprendizaje automático y, por último, los modelos fueron evaluados mediante métricas de desempeño con el propósito de determinar cuál ofrecía una mejor capacidad para clasificar el nivel de riesgo de inundación.

2.1 Construcción de la variable objetivo

La variable objetivo fue creada para clasificar el nivel de riesgo de inundación en tres categorías: Bajo, Medio y Alto. Para construir esta clasificación se consideraron tres factores principales: la precipitación anual, la altitud y el número de eventos históricos registrados por el Servicio Nacional de Gestión de Riesgos y Emergencias (SNGRE).

La precipitación fue utilizada porque un mayor volumen de lluvia incrementa la probabilidad de inundaciones debido a la saturación del suelo y al aumento del caudal de los ríos. La altitud también fue considerada, ya que las zonas de menor elevación presentan una mayor tendencia a la acumulación de agua. Finalmente, los eventos históricos permitieron incorporar información sobre la recurrencia de inundaciones en cada zona.

Para asignar la categoría de riesgo se implementó un sistema de puntuación en el que cada variable aporta un valor según el nivel de amenaza que representa. La suma de estos valores determina la clasificación final: riesgo Bajo cuando la puntuación es baja, riesgo Medio cuando presenta condiciones moderadas y riesgo Alto cuando coinciden varios factores de vulnerabilidad. Esta metodología permitió construir una variable objetivo consistente y adecuada para el entrenamiento de los modelos de aprendizaje automático.

2.2 Variables predictoras y variable derivada

Para la construcción del modelo predictivo, se realizó un proceso de selección y preparación de variables, fundamentado en su capacidad para representar los factores de vulnerabilidad frente a riesgos de inundación en la provincia del Guayas. Se seleccionaron variables demográficas y climáticas que permiten cuantificar el nivel de exposición y sensibilidad del territorio.

- **Población y densidad poblacional:** estas variables demográficas permiten cuantificar la exposición humana. Una mayor densidad poblacional en zonas de riesgo implica una mayor criticidad en la gestión de emergencias.
- **Altitud:** factor crítico en la modelación de riesgos geológicos y climáticos. La altitud condiciona la susceptibilidad del terreno a fenómenos de inundación y es un determinante básico en el clima regional.
- **Precipitación anual:** se utiliza como el principal indicador de forzamiento meteorológico. La variabilidad en los niveles de precipitación es un predictor esencial para estimar el riesgo de saturación hídrica del suelo.

- **Variable derivada (pendiente):** se construyó una variable derivada, denominada *pendiente_derivada*, calculada mediante el cociente entre la altitud y la superficie de cada parroquia. Esta variable actúa como un proxy de la inclinación del terreno, ya que una pendiente más pronunciada está correlacionada con una mayor velocidad de escorrentía, un factor determinante en la generación de riesgos por inundación.

Los valores nulos hallados en las variables de altitud y precipitación_anual fueron tratados mediante la imputación por la media de su respectiva columna, permitiendo preservar la integridad del conjunto de datos.

Se implementó `StandardScaler` para reescalar todas las variables numéricas a una distribución con media cero y desviación estándar unitaria. Este paso es indispensable para evitar que variables con magnitudes superiores sesguen la influencia de otras variables.

2.3 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio se realizó sobre el dataset final ya integrado y depurado (54 parroquias de la provincia del Guayas, 9 variables predictoras, sin valores nulos ni duplicados), construido a partir de capas geográficas oficiales (código DPA_PARROQ), registros históricos de eventos de inundación del SNGRE y densidad poblacional del INEC, unificados mediante el código oficial de parroquia.

La variable objetivo se construyó a partir de un Índice de Riesgo Compuesto (IRC), que combina de forma ponderada un índice de exposición hidrológica (IEH, 40 %), un índice de vulnerabilidad topográfica (IVT, 35 %) y un índice de exposición socio-territorial (IES, 25 %), clasificando cada parroquia en Bajo/Medio/Alto mediante terciles estadísticos. Esta estrategia produjo un conjunto de clases razonablemente balanceado: 35,2 % Alto, 33,3 % Bajo y 31,5 % Medio, lo que evita el sesgo hacia una clase mayoritaria y favorece una evaluación más confiable de los modelos de clasificación.




Figura 1: Distribución de clases – Riesgo de Inundación.

La matriz de correlación entre las variables predictoras (Figura 2) confirma relaciones esperadas: las variables asociadas al riesgo hidrológico (precipitación anual, número de eventos históricos e IEH) se agrupan con correlaciones altas entre sí, mientras que la altitud se comporta como la variable más independiente del conjunto.




Figura 2: Matriz de correlación entre las variables predictoras.

El análisis de boxplots por nivel de riesgo muestra una separación visible en variables como IEH, IVT e IRC, con medianas que aumentan de forma consistente de Bajo a Alto, lo cual respalda la validez interna de la variable objetivo construida. La densidad poblacional y el número de eventos históricos muestran mayor dispersión y presencia de valores atípicos, principalmente asociados a Guayaquil.




Figura 3: Distribución de variables predictoras por nivel de riesgo.

Finalmente, se realizó un análisis de Factor de Inflación de la Varianza (VIF) para evaluar multicolinealidad entre las variables predictoras. Los resultados muestran un problema severo: `precip_anual_mm`, `n_eventos_inundacion`, `IEH`, `densidad_pob_km2` e `IES` presentan VIF infinito, y `años_afectados` alcanza un VIF de 90,9, mientras que `IVT` registra 23,3. Solo la altitud ($VIF = 1,9$) se mantiene dentro de un rango aceptable. Esto ocurre porque `IEH` e `IES` son combinaciones lineales directas de otras variables ya incluidas en el mismo conjunto (precipitación, eventos históricos y densidad poblacional), lo que genera dependencia perfecta entre ellas. Este hallazgo es relevante para la etapa de modelado: se recomienda excluir las variables originales que ya están representadas dentro de los índices compuestos (o viceversa) antes de entrenar modelos sensibles a la colinealidad, como la Regresión Logística, mientras que modelos basados en árboles (Árbol de Decisión, Random Forest) son comparativamente más robustos frente a este problema.

2.4 Modelos de clasificación aplicados

Para el modelado se utilizó el conjunto final de 54 parroquias con las variables predictoras validadas en el EDA (excluyendo el IRC, ya que la variable objetivo se deriva directamente de él, lo que evitaría fuga de información). Los datos se dividieron en un 75 % para entrenamiento (40 parroquias) y 25 % para prueba (14 parroquias), utilizando muestreo estratificado para preservar la proporción de clases Bajo/Medio/Alto, y se aplicó estandarización (`StandardScaler`) a los modelos sensibles a la escala.

Se implementaron cuatro modelos:

1. Regresión Logística multinomial con ponderación balanceada de clases.
2. Árbol de Decisión (profundidad máxima 4, mínimo 3 muestras por hoja).
3. Un modelo de Ensamble tipo *Voting* (soft) que combina Regresión Logística, Árbol de

Decisión, SVM y Random Forest.

4. Un Random Forest optimizado mediante **GridSearchCV**, explorando 108 combinaciones de hiperparámetros (número de árboles, profundidad máxima, mínimo de muestras por división y por hoja) con validación cruzada estratificada de 5 particiones y F1-macro como métrica de selección.

Dado el tamaño reducido del dataset ($n = 54$), se aplicó validación cruzada adicional sobre los modelos base para obtener una estimación más estable del desempeño antes de evaluar en el conjunto de prueba.

2.5 Resultados obtenidos

La tabla comparativa muestra el desempeño de los cuatro modelos sobre el conjunto de prueba:

Tabla 1: Comparación de métricas de desempeño por modelo (conjunto de prueba).

Modelo	Accuracy	Precision	Recall	F1-macro
Regresión Logística	0,857	0,889	0,867	0,859
Árbol de Decisión	0,714	–	–	0,715
Ensamble (RL + DT + SVM + RF)	0,929	–	–	0,926
Random Forest (GridSearchCV)	0,786	–	–	0,789

El Ensamble (RL + DT + SVM + RF) fue el modelo con mejor desempeño general, con Accuracy = 0,929 y F1-macro = 0,926. El Random Forest optimizado con GridSearchCV alcanzó Accuracy = 0,786 y F1-macro = 0,789, con los mejores hiperparámetros: 200 árboles, profundidad máxima 5, mínimo de 2 muestras por hoja y 2 por división (F1-macro en validación cruzada = 0,769).

En cuanto al Recall de la clase “Alto” –la más crítica para la gestión de riesgo–, los cuatro modelos coincidieron en un valor de 0,800, es decir, el sistema identifica correctamente 4 de cada 5 parroquias de riesgo alto en el conjunto de prueba. Las curvas ROC del modelo optimizado muestran un AUC de 0,956 para la clase Alto y de 1,000 para Bajo y Medio, con un AUC promedio (macro) de 0,985, lo que indica una excelente capacidad de discriminación entre clases pese al tamaño reducido de la muestra.




Figura 4: Comparación de métricas de desempeño entre los cuatro modelos.




Figura 5: Curva ROC del modelo Random Forest optimizado, por clase de riesgo.

El análisis de importancia de variables del Random Forest optimizado identificó al Índice de Exposición Hidrológica (IEH, 17,1 %), al Índice de Exposición Socio-territorial (IES, 15,9 %) y a la densidad poblacional (14,2 %) como los predictores más influyentes, seguidos por el

número de eventos históricos de inundación (13,3 %) y la altitud (12,1 %). Esto confirma que la exposición climática combinada con la presión demográfica son los factores determinantes del riesgo de inundación a nivel parroquial en el Guayas.




Figura 6: Importancia de variables del modelo Random Forest optimizado.

3 Discusión y limitaciones del estudio

El Recall fue seleccionado como la métrica más relevante para este problema: en el contexto de gestión de riesgo de inundación, un Falso Negativo (clasificar como Bajo o Medio una parroquia que en realidad es de riesgo Alto) tiene consecuencias mucho más graves que un Falso Positivo, ya que deja a la población sin medidas preventivas frente a un peligro real. Un Falso Positivo, en cambio, solo implica una asignación de recursos preventivos superior a la estrictamente necesaria, un costo comparativamente menor.

A pesar de los buenos resultados generales, deben señalarse varias limitaciones:

1. El conjunto de prueba es muy pequeño (14 parroquias, 4–5 por clase), por lo que cada acierto o error individual tiene un peso proporcionalmente alto en las métricas; el hecho de que las cuatro variantes de modelo obtuvieran exactamente el mismo Recall (0,800) para la clase Alto es consistente con este tamaño muestral reducido (equivalente a acertar 4 de 5 casos) y no debe interpretarse como evidencia fuerte de equivalencia real entre los modelos.
2. La validación cruzada mostró un desempeño más modesto y con mayor dispersión que la evaluación puntual sobre el conjunto de prueba (F1-macro de $0,824 \pm 0,123$ para Regresión Logística y de $0,679 \pm 0,188$ para el Árbol de Decisión), lo que sugiere que los resultados sobre el test set podrían ser optimistas y que el desempeño real del

sistema, ante datos nuevos, es probablemente más variable de lo que aparenta la tabla comparativa.

3. La multicolinealidad severa detectada en el EDA (VIF infinito entre precipitación, número de eventos, densidad poblacional y los índices derivados IEH/IES) afecta en mayor medida a la Regresión Logística, cuyos coeficientes pueden volverse inestables ante variables redundantes; los modelos basados en árboles (Árbol de Decisión, Random Forest, y por extensión el Ensamble) son más robustos a este problema, lo que ayuda a explicar por qué el Ensamble superó consistentemente a los modelos individuales.
4. El estudio hereda las limitaciones de los datos de origen: la precipitación se estima a nivel de centroide de estación climática, sin resolución espacial dentro de cada parroquia, y los registros históricos de eventos de inundación del SNGRE dependen de reportes de situación (SitReps) que pueden estar sujetos a subregistro, especialmente en parroquias rurales con menor cobertura institucional.

4 Conclusión

El presente proyecto logró construir un pipeline completo de aprendizaje automático capaz de clasificar el riesgo de inundación de las 54 parroquias de la provincia del Guayas en las categorías Bajo, Medio y Alto, integrando fuentes oficiales de información climática, topográfica y socio-territorial mediante un cruce por código oficial de parroquia. El modelo de Ensamble (Regresión Logística, Árbol de Decisión, SVM y Random Forest) obtuvo el mejor desempeño global ($F1\text{-macro} = 0,926$, $AUC\text{ promedio} = 0,985$), y el análisis de importancia de variables confirmó que la exposición hidrológica y la densidad poblacional son los factores más determinantes del riesgo, resultados alineados con la literatura sobre vulnerabilidad territorial frente a inundaciones.

No obstante, el tamaño reducido de la muestra y las limitaciones propias de los datos abiertos utilizados exigen interpretar estos resultados como una primera aproximación útil para apoyar la toma de decisiones, y no como un sistema de alerta definitivo. Los resultados del modelo optimizado se integraron a una aplicación web con visualización geográfica interactiva, que permite consultar de forma accesible el nivel de riesgo estimado por parroquia, apoyando así la gestión de riesgo a nivel local. Como trabajo futuro, se recomienda incorporar variables de uso de suelo y porcentaje de área urbanizada, integrar imágenes satelitales (por ejemplo, Sentinel-1 SAR) para la detección de inundaciones en tiempo real, y extender este enfoque metodológico a otras provincias costeras del Ecuador con similar exposición a eventos hidrometeorológicos extremos.

Referencias

1. Tauzer, E., Borbor-Cordova, M. J., Mendoza, J., De La Cuadra, T., Cunalata, J., & Stewart-Ibarra, A. M. (2019). A participatory community case study of periurban

- coastal flood vulnerability in southern Ecuador. *PLoS ONE*, 14 (10), e0224171. <https://doi.org/10.1371/journal.pone.0224171>
2. Instituto Nacional de Estadística y Censos (INEC). *Censo de Población y Vivienda 2022 – División político-administrativa y densidad poblacional por parroquia*.
 3. Instituto Nacional de Meteorología e Hidrología (INAMHI). *Registros históricos de precipitación por estación climática*.
 4. Servicio Nacional de Gestión de Riesgos y Emergencias (SNGRE). *Registros históricos de eventos de inundación por parroquia (Informes de Situación – SitReps)*.
 5. NASA POWER (Prediction Of Worldwide Energy Resources). *Datos climáticos de precipitación a nivel de centroide geográfico*.
 6. Bruce, P. (Il.), Bruce, A. & Gedeck, P. (2022). *Estadística práctica para ciencia de datos con R y Python* (2.^a ed.). Marcombo. <https://elibro.net/es/lc/uguayaquil/titulos/281858>
 7. Sarasa Cabezuelo, A. (2017). *Gestión de la información web usando Python*. Editorial UOC. <https://elibro.net/es/lc/uguayaquil/titulos/114201>
 8. Python Visualization. (s.f.). *Using Folium with Flask*. Folium Documentation. Recuperado el 9 de julio de 2026, de https://python-visualization.github.io/folium/latest/advanced_guide/flask.html
 9. Rodríguez, D. (2024, 13 de diciembre). *Tutorial: Creando un mapa interactivo con Folium en Python*. Analytics Lane. <https://www.analyticslane.com/2024/12/13/tutorial-creando-un-mapa-interactivo-con-folium-en-python/>